

第十二章重点（特征值与奇异值）

特征值与特征向量

• Power Iteration计算主特征值与特征向量

◦ 主特征值的定义：

The **dominant eigenvalue** λ_{\max} of A : an eigenvalue λ_i s.t. $|\lambda_i| > |\lambda_j|$ for $i \neq j$. (最大的特征值)

◦ 主特征向量的定义：

If dominant eigenvalue exists, an eigenvector v_{\max} associated to λ_{\max} is called a **dominant eigenvector**. (最大特征值对应的特征向量)

◦ 用一个矩阵 A 对一个随机选取的向量 x 不断地进行线性变换，即 $\lim_{n \rightarrow \infty} A^n x$ ，结果将会无限逼近矩阵 A 的主特征向量的**倍数**

◦ 已知特征向量 v_{\max} ，如何计算特征值 λ_{\max} ：

- 利用**Rayleigh quotient**（瑞利商）： $\lambda = \frac{v^T A v}{v^T v}$ ，这是为了避免用上面最开始的方法得到主特征向量倍数的结果太大，因此对结果进行了**标准化** (normalization)

瑞利商推导过程：

$$A v = \lambda v \Rightarrow v^T A v = v^T \lambda v \Rightarrow v^T A v = \lambda v^T v \Rightarrow \lambda = \frac{v^T A v}{v^T v}$$

◦ 最终Power Iteration的算法流程如下：

$x_0 = \text{Initial Vector}$

for $j = 1, 2, \dots$ **do**

$$v_{j-1} = \frac{x_{j-1}}{\|x_{j-1}\|_2}$$

$$x_j = A v_{j-1}$$

$$v_{\max} = \frac{x_j}{\|x_j\|_2}$$

$$\lambda_{\max} = v_{\max}^T A v_{\max}$$

• Power Iteration收敛性的证明

◦ Power Iteration收敛性定理：

Let A be an $n \times n$ matrix with real eigenvalues $\lambda_1, \dots, \lambda_n$ satisfying $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$. Assume that the eigenvalues of A span \mathbb{R}^n . For almost every initial vector, Power Iteration converges to an eigenvector associated to λ_1 .

◦ 证明：

Let v_1, \dots, v_n be the eigenvectors w.r.t. $\lambda_1, \dots, \lambda_n$ respectively.

The initial vector x_0 can be expressed as $c_1 v_1 + \dots + c_n v_n$ where $c_1 \neq 0$.

Applying Power Iteration yields:

$$A x_0 = c_1 \lambda_1 v_1 + \dots + c_n \lambda_n v_n$$

$$A^2 x_0 = c_1 \lambda_1^2 v_1 + \dots + c_n \lambda_n^2 v_n$$

\vdots

$$A^k x_0 = c_1 \lambda_1^k v_1 + \dots + c_n \lambda_n^k v_n$$

$$\lim_{k \rightarrow \infty} \frac{A^k x_0}{\lambda_1^k} = \lim_{k \rightarrow \infty} [c_1 v_1 + \dots + c_n \left(\frac{\lambda_n}{\lambda_1}\right)^k v_n] = c_1 v_1$$

• 学会如何介绍Page Rank算法（写一个段落来介绍这个算法，介绍它的主要思想/目的/大致思路，如果特征值不满足要求，如何调整Power Iteration方法）

◦ Page Rank算法用于**衡量每个网页的相对重要性**。算法的核心是为每个网页 i 分配一个分数 r_i ，代表其重要性。如果 $r_i > r_j$ ，则网页 i 比网页 j 更重要。**所有网页的分数需要规范化，使得所有分数之和为1。**

◦ Page Rank的核心观点包括：

- 重要的网页会 from 其他重要网页获得链接，**网页通过链接给其他网页“投票”**，链接越多，该网页越重要；
- **一个网页的投票权只有一次**，如果它链接到多个网页，则其投票权需要分割；
- 一个具有**高分的网页**可能具有来自其他**高分网页的链接**或有指向**高分网页的外链**；
- 来自**重要网页的链接**比来自**不重要网页的链接**对提高网页重要性的**作用更大**。

◦ 如果在算法中遇到特征值不满足要求的情况，如矩阵特征值不为1或难以计算特征值，需要调整Power iteration方法。

- 如果**邻接矩阵的特征值不为1**：

使邻接矩阵具有特征值1，我们可以将矩阵转化为**列随机矩阵** (column stochastic)，列随机矩阵定义如下：

- 所有条目都非负

- 每一列的元素和都为1
- 1总是特征值
- 因为每一列的元素和都为1，所以其最大列和也为1，也称1-范数 $\max(\|A\|_1) = 1$
- 矩阵的特征值为1，但**获取的特征向量的计算成本很高**：
根据**Perron-Frobenius定理**：如果矩阵 A 中的每个条目都是正的，那么其存在一个正实数 λ 为 A 的主特征值。在Page Rank构建的列随机矩阵中，这个定理保证1不仅是一个特征值，而且是最大的特征值。
因此，我们要做的事情就是保证Page Rank构建的矩阵是
 - **列随机的** (column stochastic)
 - **符号为正的** (positive)
 - **稀疏的** (sparse)

奇异值分解 (SVD)

• SVD计算

◦ 定义：

令 A 为一个 $m \times n$ 的矩阵， $U: \{u_1, \dots, u_m\}$ 和 $V: \{v_1, \dots, v_n\}$ 是两个正交基集，同时有 s_1, \dots, s_n 满足当 $1 \leq i \leq n$ 时 $Av_i = s_i u_i$ ，此时：

- v_i 称为 A 的右奇异向量
- u_i 称为 A 的左奇异向量
- s_i 称为 A 的奇异值

USV^T 是 A 的奇异值分解 (Singular Value Decomposition)，其中 S 是一个 $m \times n$ 的对角矩阵，其对角线上的条目是 s_i ， $s_i = \sqrt{\lambda_i}$

◦ 求 U ， S ， V 矩阵：

设 $m \leq n$ ，给定以下量：

- $\lambda_1, \lambda_2, \dots, \lambda_n$: $A^T A$ 的特征值集合，其中 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$
- v_1, v_2, \dots, v_n 是上述特征值对应的特征向量

各个 s_i 和 u_i ($1 \leq i \leq m$)可由以下公式计算得到：

- $s_i = \sqrt{\lambda_i}$
- $u_i = \begin{cases} \frac{Av_i}{s_i} & \text{if } \lambda_i \neq 0 \\ \text{an unit vector orthogonal to } u_1, u_2, \dots, u_{i-1} & \text{otherwise} \end{cases}$

• SVD引理、推论和性质的证明

◦ 引理1：令 A 为一个 $m \times n$ 的矩阵， $A^T A$ 和 AA^T 的特征值都是非负的

- 证明：令 v 为 $A^T A$ 的一个单位特征向量且 $A^T Av = \lambda v$ 。那么 $0 \leq \|Av\|^2 = v^T A^T Av = \lambda v^T v = \lambda$

◦ 推论1： AA^T 和 $A^T A$ 是对称的

- 证明： $(AA^T)^T = (A^T)^T A^T = AA^T$ 。同理， $(A^T A)^T = A^T A$

◦ 推论2： u_1, u_2, \dots, u_m 构成了 AA^T 的组标准正交 (orthonormal) 特征向量集合

- 证明：

- 单位性 (Unitary) : $u_i^T u_i = \frac{Av_i^T Av_i}{s_i^2} = \frac{v_i^T A^T Av_i}{s_i^2} = \frac{\lambda_i v_i^T v_i}{\lambda_i} = 1$
- 正交性 (Orthogonality) : $u_i^T u_j = \frac{Av_i^T Av_j}{s_i s_j} = \frac{v_i^T A^T Av_j}{s_i s_j} = \frac{\lambda v_i^T v_j}{s_i s_j} = 0$ ，其中 $i \neq j$
- 特征向量 (Eigenvector) : $AA^T u_i = \frac{AA^T Av_i}{s_i} = s_i^2 \frac{Av_i}{s_i} = \lambda_i u_i$

◦ 推论3：矩阵 $A = USV^T$ 的秩 (rank) 是 S 中非零条目的数量

- 定义：

秩 (rank) 在一个 $m \times n$ 的矩阵 A 中代表的是其线性无关的行 (列) 的数量

- 证明：

U 和 V 是正交的，因此它们也是可逆的， $\text{rank}(A) = \text{rank}(S)$ ，因为 S 是个对角矩阵，所以 A 的秩是 S 中非零条目的数量

◦ 推论4：如果 A 是一个 $n \times n$ 的矩阵，那么 $|\det(A)| = s_1 \cdots s_n$

- 证明：

因为 $U^T U = I$ ， $\det(U) = 1$ 或 $\det(U) = -1$ ，同理 $\det(V^T) = \det(V) = 1$ 或 $\det(V^T) = \det(V) = -1$ 。因此 $|\det(A)| = |\det(USV^T)| = |\det(U)| \cdot |\det(S)| \cdot |\det(V^T)| = s_1 \cdots s_n$

◦ 推论5：如果 A 是一个可逆的 $n \times n$ 矩阵，那么 $A^{-1} = VS^{-1}U^T$

- 证明：

我们可知 S 矩阵同样是可逆的，根据SVD的定义， U 和 V^T 也是可逆的，拓展可得 $U^{-1} = U^T$ 和 $(V^T)^{-1} = V$ ，最终得到 $A^{-1} = (USV^T)^{-1} = (V^T)^{-1} S^{-1} U^{-1} = VS^{-1}U^T$

◦ 推论6： $m \times n$ 的矩阵 A 可以被改写成rank为1的矩阵的和，即

$$A = \sum_{i=1}^r s_i u_i v_i^T$$

其中 r 是 A 的秩，且 u_i 和 v_i 分别是 U 和 V 的第 i 列

▪ 证明:

$$\begin{aligned} A &= USV^\top = U \begin{bmatrix} s_1 & & \\ & \ddots & \\ & & s_r \end{bmatrix} V^\top \\ &= U \left(\begin{bmatrix} s_1 \\ \\ \\ \end{bmatrix} + \begin{bmatrix} \\ s_2 \\ \\ \end{bmatrix} + \cdots + \begin{bmatrix} \\ \\ s_r \end{bmatrix} \right) V^\top \\ &= s_1 u_1 v_1^\top + s_2 u_2 v_2^\top + \cdots + s_r u_r v_r^\top \end{aligned}$$